



**TECNOLÓGICO  
NACIONAL DE MÉXICO**

# **Instituto Tecnológico Nacional de México, Campus Culiacán**

**Semestre VIII**

**Inteligencia Artificial**

**11:00 – 12:00**

**Zuriel Dathan Mora Félix**

**Unidad 2, Tarea 1: Investigación sobre el  
Aprendizaje Automático**

**Meza López Jorge Gael**

**Félix Avendaño Mateo**

**09 de marzo del 2025. Culiacán, Sinaloa**

## **Aprendizaje Automático**

El aprendizaje automático no es Inteligencia Artificial (IA) en sí mismo y es mucho más que automatizar un montón de tareas simples. Es una rama específica dedicada a ayudar a las computadoras a aprender de los humanos y cómo interactuar con nosotros de una manera similar a la de los humanos.

La IA, que impulsa la mayoría de las aplicaciones modernas, se debe a los algoritmos diseñados rigurosamente creados por desarrolladores e ingenieros informáticos. Toneladas de conjuntos de datos se construyen y reconstruyen hasta que están listos para funcionar. Luego, las máquinas las usan para ayudar a anticipar diferentes aspectos del comportamiento humano.

La mayoría de los algoritmos siguen un patrón establecido. Los humanos no suelen hacer esto, que es donde los científicos aún luchan para desarrollar una IA verdaderamente autónoma.

Los problemas con un resultado claramente definible son los que el aprendizaje automático maneja mejor. El reconocimiento de imágenes, la búsqueda de patrones en datos faltantes y la percepción de un lenguaje claro e inequívoco son cosas que la IA puede hacer bien.

También se usa con frecuencia para encontrar discrepancias en las transacciones financieras, hacer predicciones basadas en patrones de datos pasados (piense en el mercado de valores) y reconocer cuando alguien le envía algún tipo de correo no deseado o correo electrónico fraudulento y lo marca como tal.

## **Adquisición de datos**

La adquisición de datos es el primer paso en el proceso de aprendizaje automático. Se refiere al acto de reunir y recopilar información relevante de diversas fuentes, tanto internas como externas. Por ejemplo, la empresa tiene posibilidad de capturar las transacciones de los clientes, el tráfico del sitio web o las lecturas de los sensores.

Por otro lado, los externos incluyen los conjuntos de bases disponibles públicamente, reseñas de redes sociales (con consentimiento) o información comprada a proveedores externos. Sin embargo, es importante elegir los que sean relevantes para el problema que el modelo de ML está tratando de resolver y que permitan al modelo identificar patrones y relaciones.

Es probable que un conjunto de datos de primera calidad garantice que los algoritmos aprendan patrones y ofrezcan predicciones exactas. Por el contrario, un conjunto de calidad inferior dará lugar a modelos sesgados o incorrectos, lo que proporcionará resultados poco fiables.

Desafíos comunes en la adquisición de datos:

- Volumen

Es una tarea ardua el gestionar volúmenes de datos necesarios para el aprendizaje automático. Además, este conjunto de datos necesita importantes capacidades de almacenamiento y procesamiento.

- Variedad

Es complicado tratar de integrar variedad de formas de datos, como son los estructurados y no estructurados. Además, es difícil reunir diferentes fuentes de datos para crear un conjunto coherente.

- Veracidad

Se refiere a la fiabilidad y la calidad de nuestra información. Existe el riesgo de un rendimiento deficiente del modelo debido a datos inexactos, incompletos o ruidosos.

## **Preprocesamiento de datos**

El preprocesamiento de datos es el proceso de transformar los datos brutos en una forma que pueda ser utilizada por un algoritmo de aprendizaje automático. El objetivo del preprocesamiento es hacer que los datos estén lo más cerca posible de estar listos para su uso, conservando al mismo tiempo la mayor cantidad de información posible.

### **El preprocesamiento puede dividirse en cuatro pasos principales:**

- 1.- Limpieza de los datos: Este paso elimina cualquier dato que sea incorrecto, incompleto o irrelevante.
- 2.- Transformación de los datos: Este paso transforma los datos en una forma más adecuada para el algoritmo de aprendizaje automático.
- 3.- Reducción de datos: Este paso reduce la cantidad de datos seleccionando sólo las características más relevantes.
- 4.- Discretización de los datos: Este paso convierte los datos en una forma más adecuada para el algoritmo de aprendizaje automático.

El preprocesamiento es el primer paso del análisis de datos, en el que se limpian, organizan y preparan los datos para su posterior análisis. Este paso es importante porque garantiza que los datos son de buena calidad y están listos para su uso en el análisis posterior.

### **Existen cinco tipos de datos:**

1. Los datos nominales son aquellos a los que se puede asignar un valor, pero éste no tiene un significado inherente. Por ejemplo, el género de una persona podría describirse como "masculino" o "femenino".
2. Los datos ordinales son aquellos a los que se puede asignar un valor, y el valor tiene una clasificación inherente. Por ejemplo, la altura de una persona podría describirse como "alta", "media" o "baja".

3. Los datos de intervalo son aquellos a los que se puede asignar un valor, y el valor tiene un orden inherente, pero la distancia entre los valores no es necesariamente igual. Por ejemplo, la temperatura de una persona podría describirse como "baja", "normal" o "alta".

4. Los datos de relación son aquellos a los que se les puede asignar un valor, y el valor tiene un orden inherente, y la distancia entre los valores es igual. Por ejemplo, el peso de una persona podría describirse como "ligero", "medio" o "pesado".

5. Los datos de texto son aquellos a los que se puede asignar un valor, pero el valor es una cadena de caracteres. Por ejemplo, el nombre de una persona podría describirse como "John Smith".

Nota: La limpieza de datos y la ETL no son lo mismo. La limpieza de datos es el proceso de identificación y limpieza de inexactitudes e incoherencias en los datos. La ETL se refiere a la extracción, transformación y carga de datos de diferentes sistemas.

## **Entrenamiento de modelo**

El proceso de entrenamiento de un modelo de aprendizaje automático comienza con una serie de pasos clave que garantizan su eficacia. Estos incluyen la recopilación de datos y el ajuste de la calidad de los mismos. La calidad del conjunto de datos impacta directamente en el rendimiento del modelo. Sin un conjunto de datos limpio y relevante, el modelo podría no generalizar bien en situaciones del mundo real.

### **Pasos previos al entrenamiento**

Antes de que un modelo pueda ser entrenado, se necesitan realizar ciertos pasos previos. La recopilación de datos implica reunir información de diversas fuentes, asegurando que sea suficiente y variada. La limpieza de datos es un paso crítico que incluye la eliminación de duplicados, el tratamiento de valores nulos y la corrección de errores. Un modelo de aprendizaje automático depende enormemente de la calidad de los datos con los que se alimenta.

### **Selección del algoritmo adecuado**

Una vez que se han cumplido los pasos previos, el siguiente desafío es elegir entre diferentes **algoritmos de aprendizaje automático**. La selección del algoritmo adecuado influye en gran medida en cómo se entrena un modelo de aprendizaje automático. Existen numerosos algoritmos disponibles, cada uno con sus ventajas y desventajas. La clave es entender el problema específico a resolver y seleccionar un algoritmo que se ajuste mejor a las características de los datos.

### **Ajuste de hiperparámetros en ML**

El **ajuste de hiperparámetros en ML** juega un papel crucial en el rendimiento del modelo. Antes de abordar este concepto, es esencial entender qué son los hiperparámetros y cómo afectan el proceso de entrenamiento.

## **Qué son los hiperparámetros**

Los hiperparámetros son parámetros que se establecen antes de comenzar el entrenamiento de un modelo. A diferencia de los parámetros del modelo, que se ajustan durante el proceso de aprendizaje, los hiperparámetros influyen directamente en la capacidad del modelo para aprender y realizar predicciones. Ejemplos comunes incluyen:

- Tasa de aprendizaje
- Número de capas en redes neuronales
- Tamaño del lote

## **Técnicas de optimización de modelos ML**

La optimización es un componente crucial en el desarrollo de modelos de Machine Learning. Las técnicas de optimización de modelos ML no solo buscan mejorar la precisión, sino que también se centran en la eficiencia en el uso de recursos. Una de las estrategias más efectivas es la regularización, que ayuda a prevenir el sobreajuste al penalizar modelos demasiado complejos. Esto resulta en un mejor rendimiento cuando se presentan datos nuevos, lo que es fundamental para aplicaciones reales.



## **Evaluación del modelo**

La evaluación de modelos de aprendizaje automático es un proceso destinado a determinar la calidad y eficacia de los modelos desarrollados para diversas tareas predictivas o descriptivas en IA.

Se basa en el uso de métricas y técnicas específicas para medir el rendimiento del modelo con datos nuevos, en particular datos que no ha visto durante su entrenamiento.

El objetivo principal es garantizar que el modelo funciona satisfactoriamente en condiciones reales y que es capaz de generalizar correctamente más allá de los datos de entrenamiento.

### **Objetivos de la evaluación de modelos**

La evaluación de modelos de aprendizaje automático tiene varios objetivos clave, cada uno de los cuales contribuye a garantizar que el modelo funcione bien, sea fiable y pueda utilizarse en aplicaciones reales de forma segura y ética. Los principales objetivos de la evaluación de modelos son los siguientes:

- Medición del rendimiento

Uno de los objetivos generales es cuantificar el rendimiento del modelo en datos que no vio cuando estaba siendo entrenado. Esto incluye medidas de precisión, recuperación, puntuación F1, error cuadrático medio, entre otras, dependiendo del tipo de modelo y de la tarea.

- Comprobación de la generalización

Es esencial comprobar que el modelo no sólo se ajusta a los datos de entrenamiento, sino que también puede funcionar con datos nuevos y desconocidos.

- Detectar el sobreaprendizaje y el infraaprendizaje

La evaluación ayuda a identificar si el modelo es demasiado complejo(*sobreajuste*) o demasiado simple(*infraajuste*). Un modelo

sobreajustado tiene una tasa de error baja en los datos de entrenamiento pero alta en los datos de prueba, mientras que un modelo infraajustado tiene un error alto tanto en los datos de entrenamiento como en los de prueba.

- Comparar modelos

Permite comparar varios modelos o varias versiones de un mismo modelo para determinar cuál funciona mejor según criterios específicos.

- Ajuste de los hiperparámetros

La evaluación del modelo se utiliza para ajustar los hiperparámetros con el fin de optimizar el rendimiento.

- Garantía de solidez y estabilidad

La evaluación pone a prueba la solidez del modelo frente a las variaciones de los datos de entrada y garantiza su estabilidad a lo largo de diferentes iteraciones y muestras de datos.

- Identificar los prejuicios

Ayuda a detectar y comprender los sesgos en las predicciones de los modelos.

- Garantizar la interpretabilidad

La evaluación ayuda a comprender cómo toma sus decisiones el modelo, en particular identificando la importancia de las distintas características.

- Validación de hipótesis

Permite verificar los supuestos subyacentes a la construcción del modelo.

- Preparativos para el despliegue

La evaluación del modelo prepara el terreno para su despliegue garantizando que el modelo está listo para su uso en entornos de producción.

## **Diferentes métodos y métricas para evaluar los modelos de aprendizaje automático**

Existen varias herramientas, métodos y métricas para evaluar los modelos de aprendizaje automático, cada uno con sus propias ventajas e inconvenientes, son los siguientes:

- División de los datos (*división entrenamiento/prueba*)

Dividir los datos en conjuntos de entrenamiento y de prueba es uno de los métodos más sencillos para evaluar un modelo de aprendizaje automático. Al dividir los datos, una parte se utiliza para entrenar el modelo y la otra para realizar análisis de rendimiento.

Este método es rápido de aplicar y proporciona una estimación inicial del rendimiento del modelo. Sin embargo, puede introducir un sesgo si los datos no están distribuidos uniformemente entre los dos conjuntos, lo que puede no reflejar correctamente la capacidad de generalización del modelo.

- *Validación cruzada*

La validación cruzada es una técnica más avanzada que divide los datos en  $k$  subconjuntos o pliegues. A continuación, el modelo se entrena  $k$  veces, utilizando cada vez  $k-1$  subconjuntos para el entrenamiento y un subconjunto diferente para la validación.

Este método ofrece una evaluación más fiable del rendimiento del modelo, ya que utiliza el conjunto completo de datos para el entrenamiento y la validación en momentos diferentes. Sin embargo, puede ser costoso desde el punto de vista informático, especialmente con grandes conjuntos de datos.

- *Validación cruzada estratificada*

La validación cruzada estratificada es una variante de la validación cruzada  $k$ -fold que garantiza que cada conjunto contenga aproximadamente la misma proporción de cada clase que el conjunto de datos completo. Esto resulta especialmente útil para conjuntos de datos desequilibrados, en los que algunas clases pueden estar infrarrepresentadas.

Este método permite evaluar mejor el rendimiento del modelo con datos no equilibrados, aunque su aplicación puede resultar más compleja.

- *Validación cruzada anidada*

La validación cruzada anidada se utiliza para ajustar los hiperparámetros mientras se evalúa el rendimiento del modelo. Combina una validación cruzada para la optimización de hiperparámetros y otra para la evaluación del modelo.

Este método proporciona una estimación más precisa del rendimiento cuando es necesario optimizar los hiperparámetros, pero es muy costoso desde el punto de vista informático.

- *Botstrap*

*El bootstrapping* es una técnica de remuestreo en la que se extraen muestras con reemplazo del conjunto de datos original para crear varios conjuntos de datos del mismo tamaño. A continuación, el modelo se evalúa en estos conjuntos para estimar su rendimiento.

Este método es especialmente útil para conjuntos de datos pequeños, ya que permite generar múltiples muestras para obtener una mejor estimación de la varianza del error. Sin embargo, puede estar sesgado si el conjunto de datos contiene muchos puntos similares.

- *Holdout Conjunto de validación*

La *retención de validación* consiste en dividir los datos en tres conjuntos distintos: un conjunto de entrenamiento, un conjunto de validación para ajustar los hiperparámetros y un conjunto de prueba para la evaluación final.

Este método es sencillo de aplicar y permite una evaluación rápida, pero requiere un gran número de conjuntos de datos para ser representativo.

### *Aprendizaje incremental*

El aprendizaje incremental consiste en actualizar continuamente el modelo con nuevos datos, lo que permite evaluar el rendimiento a medida que se dispone de nuevos datos.

Este método es especialmente útil para flujos de datos continuos y conjuntos de datos muy grandes. Sin embargo, su aplicación es compleja y requiere algoritmos diseñados específicamente para el aprendizaje incremental.

- Análisis de *las curvas de aprendizaje*

El análisis de la curva de aprendizaje consiste en trazar el rendimiento del modelo en función del tamaño del conjunto de entrenamiento para comprender cómo afecta al rendimiento la adición de más datos.

Este método puede identificar si el modelo sufre un ajuste insuficiente o excesivo, aunque requiere varias iteraciones de entrenamiento, lo que puede resultar costoso desde el punto de vista informático.

- Pruebas de *robustez*

Las pruebas de robustez evalúan el rendimiento del modelo con datos ligeramente alterados o ruidosos (es decir, a los que se ha añadido ruido) para comprobar su solidez. Este método garantiza que el modelo funcione bien en diversas condiciones del mundo real, aunque puede requerir la creación de datos alterados, lo que puede resultar complejo de aplicar.

- Simulación y escenarios controlados

Las simulaciones y los escenarios controlados utilizan conjuntos de datos sintéticos o simulados o conjuntos de datos simulados para poner a prueba el modelo en condiciones específicas y comprender sus limitaciones. Este método permite probar hipótesis específicas y comprender las limitaciones del modelo. Sin embargo, los resultados obtenidos no siempre pueden generalizarse a los datos reales.

## **Implementación del modelo**

Los pasos básicos para crear un plan de implementación de ML se describen en cinco sencillos pasos a continuación.

### **1.- Establecer una visión**

El negocio y la TI deben trabajar juntos para establecer una visión y definir objetivos claros para una implementación de ML. Los objetivos podrían ser tan simples como mejorar la precisión del sistema de detección de fraude hasta mejorar la eficiencia operativa general, pero se necesita una alineación comercial y de TI y el acuerdo para trabajar hacia un objetivo común. Sin una comprensión clara de lo que desea lograr, es difícil medir el éxito.

### **2.- Definir los requisitos de datos**

Los datos son quizás el elemento más importante necesario para el éxito de una implementación de aprendizaje automático. Recopilar, almacenar y alimentar al sistema con grandes cantidades de datos confiables es la clave para mejorar la precisión de los algoritmos de aprendizaje automático.

### **3.- Establecer roles y responsabilidades**

Cualquier implementación de tecnología exitosa requiere la integración en todo el panorama organizacional que está estratégicamente dirigida por una función de gestión sólida, un establecimiento claro de roles y responsabilidades e integración cultural. Comience con la creación de equipos de soluciones integrados con representantes de TI, marketing, ventas y otras partes interesadas necesarias que se reúnan regularmente durante el proyecto para revisar el progreso y garantizar una coordinación adecuada con sus respectivos grupos.

### **4.- Configurar un proceso de gestión de cambios**

Las inserciones de tecnología a menudo fallan debido a la falta de procesos adecuados de gestión de cambios, que incluye examinar los

procesos comerciales actuales y rediseñarlos en función del modelo comercial actualizado.

#### **5.- Establecer seguimiento y revalidación**

Para garantizar que los modelos de AA sigan siendo relevantes y, en última instancia, generen valor comercial, deben actualizarse, capacitarse y validarse continuamente. Para lograr esto, las organizaciones deben asegurarse de que cualquier plan de implementación de ML incluya la capacidad de actualizar sus criterios en función de los resultados evaluados e incorporar cantidades de datos mejoradas y crecientes. También es importante medir cómo el algoritmo ML afecta los objetivos comerciales más amplios.



## **Similitudes y Diferencias entre el Modelo Cognitivo y el Aprendizaje Automático**

<b>Aspecto</b>	<b>Modelo Cognitivo</b>	<b>Aprendizaje Automático</b>	<b>Similitudes / Diferencias</b>
Definición	Explica cómo los humanos procesan información.	Proceso en el que las máquinas aprenden patrones a partir de datos.	Ambos buscan modelar el aprendizaje, pero en distintos sistemas (humano vs máquina).
Entrada de Datos	Percepción sensorial (vista, oído, etc.).	Datos estructurados y no estructurados.	En ambos casos se requiere una fuente de información para aprender.
Procesamiento	Atención, memoria, y razonamiento.	Algoritmos y modelos matemáticos.	El cerebro usa mecanismos biológicos, mientras que las máquinas usan

			cálculos matemáticos.
Almacenamiento	Memoria de corto y largo plazo.	Bases de datos y almacenamiento en caché.	Ambos sistemas requieren almacenamiento para usar información aprendida en el futuro.
Generalización	Aplicar conocimientos previos a nuevas situaciones.	Predicción en datos no vistos previamente.	Ambos buscan extrapolar patrones aprendidos a nuevos contextos.
Adaptación	Aprendizaje a partir de nuevas experiencias.	Ajuste del modelo basado en nuevos datos.	Ambos mejoran con experiencia, aunque en el cerebro es más flexible.
Errores y Corrección	Retroalimentación y aprendizaje	Optimización del modelo con técnicas como	Ambos tienen mecanismos de ajuste, aunque los humanos

	por ensayo y error.	backpropagation.	pueden aprender sin retroalimentación explícita.
Decisión	Basada en lógica, emociones y contexto.	Basada en cálculos probabilísticos.	Las decisiones humanas son más subjetivas, mientras que las máquinas siguen patrones matemáticos.
Capacidad de Explicación	Justificación subjetiva del conocimiento.	Interpretabilidad de modelos (ej. árboles de decisión, SHAP).	En humanos es más abstracta, en máquinas depende del modelo.

## Referencias

- Torres, B. (2019, 24 julio). *¿Qué es el aprendizaje automático y cómo funciona?* - UNAM Global. UNAM Global - de la Comunidad Para la Comunidad.  
[https://unamglobal.unam.mx/global\\_revista/que-es-el-aprendizaje-automatico-y-como-funciona/](https://unamglobal.unam.mx/global_revista/que-es-el-aprendizaje-automatico-y-como-funciona/)
- Guerrero, B. (2024, 25 octubre). *La adquisición de datos en el aprendizaje automático*. Emeritus Latam.  
<https://latam.emeritus.org/blogs/la-adquisicion-de-datos-en-el-aprendizaje-automatico/>
- Arabella. (2023, 25 septiembre). *Preprocesamiento de datos*. TechEdu. <https://techlib.net/techedu/preprocesamiento-de-datos/>
- adviesbedrijven.nl. (2024, 19 diciembre). *¿Cómo se entrena un modelo de aprendizaje automático?*  
<https://vivomundo.es/como-se-entrena-un-modelo-de-aprendizaje-automatico/>
- *Técnicas de evaluación de modelos de aprendizaje automático*. (s. f.). <https://es.innovatiana.com/post/how-to-evaluate-ai-models>
- IT Digital Media Group. (2021, 29 julio). *5 pasos para la implementación del aprendizaje automático*. Gestión de Información | Discover The New.

<https://discoverthenew.ituser.es/predictive-analytics/2021/07/5-pasos-para-la-implementacion-del-aprendizaje-automatico>